deer-flow + OpenViking + pacgate-ai 网关 集成手册

> 面向律师事务所技术团队与运维工程师 版本 0.2.0 — 2026-10-05 (Pacgate-ai v0.1.23) 中文版（PDF 见 `./pdf/`）

---

1. 手册说明

本手册面向需要部署、运维与理解 **deer-flow（研究工作空间）+ OpenViking（长期记忆）+ pacgate-ai 网关（法律元数据与 RAG 服务）** 三位一体的技术团队。

它回答三个问题：

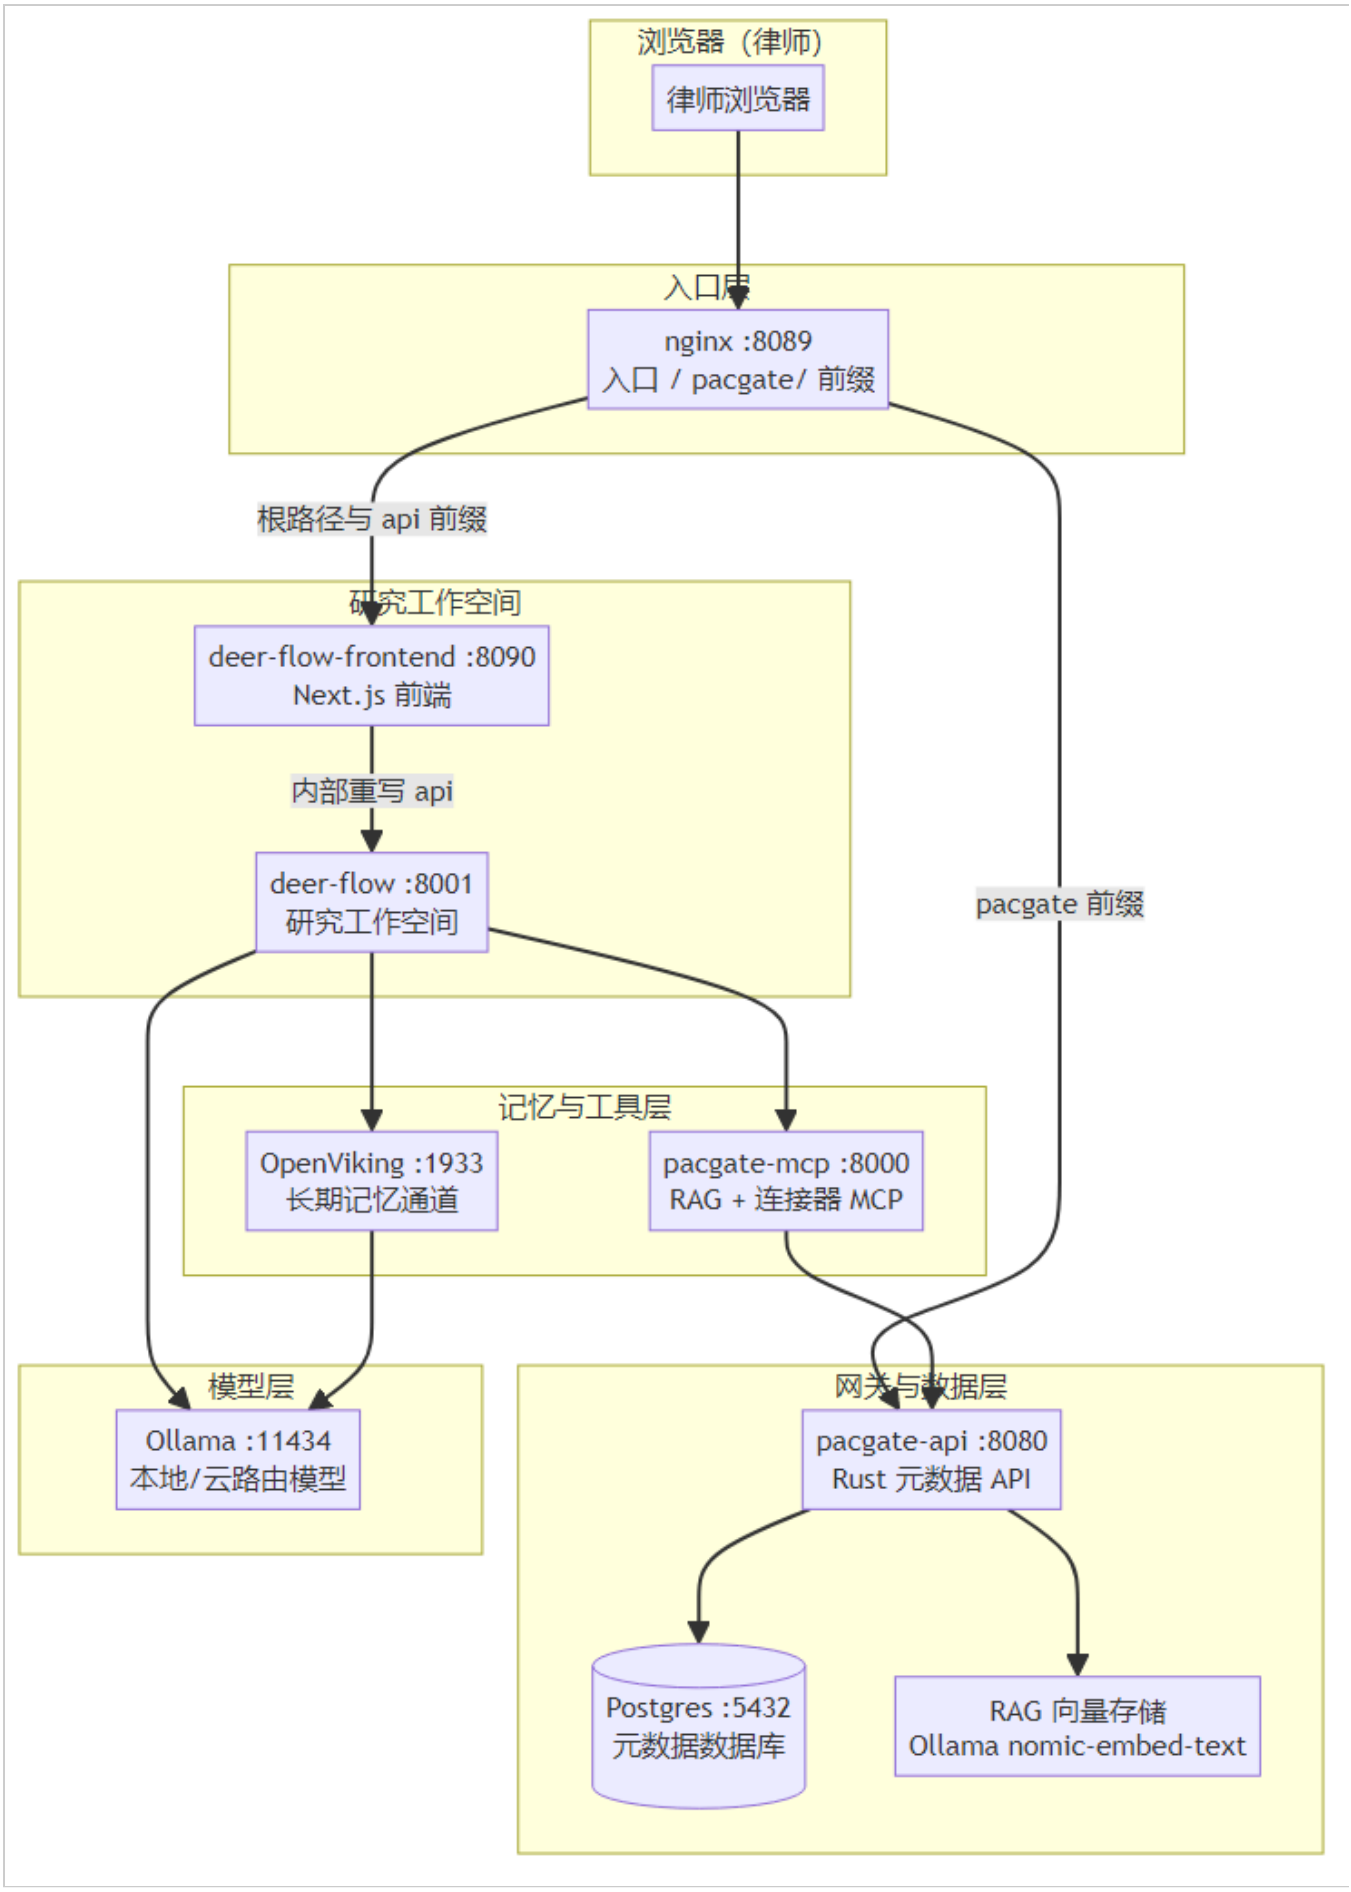
1. **这三者如何连接？** —— 架构与数据流
2. **每个组件做什么？** —— 功能与职责
3. **如何部署与排障？** —— 安装步骤与常见问题

> **红线**：本系统中的所有 AI 输出均为**律师复核前的草稿**，绝不构成最终法律意见，也绝不静默捏造事实。这一原则贯穿全部组件。

---

2. 系统架构

2.1 三层数据流


浏览器（律师）
律师浏览器
入口层
nginx :8089
入口 / pacgate/ 前缀
根路径与 api 前缀
研究工作空间
deer-flow-frontend :8090
Next.js 前端
内部重写 api
deer-flow :8001
研究工作空间
pacgate 前缀
记忆与工具层
OpenViking :1933
长期记忆通道
pacgate-mcp :8000
RAG + 连接器 MCP
模型层
Ollama :11434
本地/云路由模型
网关与数据层
pacgate-api :8080
Rust 元数据 API
Postgres :5432
元数据数据库
RAG 向量存储
Ollama nomic-embed-text

2.2 组件职责

组件	端口	职责	实现
deer-flow	8001	研究工作空间：多步骤检索、文件分析、报告生成	`ghcr.io/jzkk720/deer-flow-pacgate:0.1.23`
deer-flow-frontend	8090	Next.js 前端，重写 `/api/*` 到 deer-flow 网关	`ghcr.io/jzkk720/deer-flow-frontend-pacgate:0.1.23`（构建时烘焙网关地址）
OpenViking	1933	长期记忆：结构化记忆、语义检索、跨会话上下文	`ghcr.io/volcengine/openviking`
pacgate-mcp	8000	向 deer-flow 暴露 RAG + 法律连接器 + 文档/工作流（FastMCP）	`ghcr.io/jzkk720/pacgate-mcp:0.1.23`
pacgate-api	8080	法律元数据：案件、文档、工作流、RAG、连接器	`ghcr.io/jzkk720/pacgate-api:0.1.23`（Rust）
pacgate-nginx	8089	统一入口，路由 `/` 、`/api/` 、`/pacgate/`	`nginx:1.27-alpine`
pacgate-db	5432	元数据数据库（租户、案件、文档、审计、RAG）	`pgvector/pgvector:pg16`
Ollama	11434	本地/云路由模型 + embedding	Windows 原生

2.3 登录与访问（客户交接）

> 以下地址为**本机（localhost）**访问入口。若通过远程访问，将 `localhost` 替换为该 AIPC 的局域网/公网地址。

访问入口	地址	用途
研究工作空间	`http://localhost:8089/research/`（或 `http://localhost:8089/`）	律师日常研究工作区（deer-flow Web UI）
pacgate-api 元数据	`http://localhost:8089/pacgate/`	机器对机器（案件/文档/工作流/RAG），通常由工具调用，无需人工登录
OpenViking 记忆	`http://localhost:1933`	长期记忆服务（MCP），通常由 AI 调用，无需人工登录

管理员账号： - 研究工作区的管理员账号为 `admin@pacgate-law.com`。密码为安装时生成的 `PACGATE_API_PASSWORD`（见客户 `.env`）。 - **首次设置**：若访问工作区显示 `/setup` 页面，说明尚未创建管理员账号，按页面提示填写邮箱与密码（与上面相同）完成创建。 - **密码来源**：密码存放在客户 AIPC 的 `deploy/client-bundle/.env`（`PACGATE_API_PASSWORD`），**请勿**提交到仓库或在公开渠道传输。

> ⚠️ **远程访问登录失败（403 "Cross-site auth request denied"）**：deer-flow 会拒绝**跨源**的登录 POST。默认仅允许 `localhost` 源（`GATEWAY_CORS_ORIGINS=http://localhost:8089,http://localhost:8090`）。若通过 **IP 或主机名**（如 `http://192.168.1.10:8089`）访问，登录会报 403。**修复**：在 `.env` 中将客户实际访问源加入 `GATEWAY_CORS_ORIGINS`（逗号分隔），然后 `docker compose up -d deer-flow` 重建：`GATEWAY_CORS_ORIGINS=http://192.168.1.10:8089,http://localhost:8089,http://localhost:8090`
>
> ⚠️ **安全提示**：`PACGATE_API_PASSWORD`、`OPENVIKING_ROOT_API_KEY` 等为**每台机器独立生成**的密钥，仅保存在该机的 `.env`（gitignored）。交接时请通过安全渠道传递，不要写入本手册。

---

3. deer-flow：研究工作空间

3.1 它是什么

deer-flow 是 Pacgate-ai 的**研究工作空间**。律师在浏览器中打开它，用自然语言下达检索、文件分析、合同审查与报告生成任务。AI 将请求拆解为多个步骤，调用工具检索知识库与文件，最后输出**带引用出处**的结构化回答。

3.2 关键技术点

deer-flow 通过**包装镜像**（wrapper image）集成 Pacgate，而非 fork 源码。它基于 `ghcr.io/bytedance/deer-flow-backend`，在其上：

- 通过 `pip install` 安装 `pacgate_deerflow_adapter` 适配器
- 通过 `config.yaml` 启用 Pacgate 记忆后端（`PacgateMemoryStorage`）
- 通过 `extensions_config.json` 注册外部 MCP 服务器

启动命令（容器内）：

```
cd backend && uv run --no-sync uvicorn app.gateway.app:app --host 0.0.0.0 --port 8001
```

3.3 模型配置

`config.yaml` 定义了 deer-flow 可用的模型列表（全部通过 Ollama 路由）。以下为**客户 AIPC 部署**实际使用的 `deploy/client-bundle/deer-flow-config.yaml` 模型：

模型	说明	用途
`ornith-1.5:9b`	Ornith 1.5 9B（本地，默认）	快速非推理模型，默认研究模型
`ornith-1.5:35b`	Ornith 1.5 35B（本地）	复杂研究任务
`nemotron-3.5-lightning:30b-a3b`	Nemotron 3.5 Lightning 30B（本地，1M 上下文）	法律推理与长上下文
`gemma4:12b-it-q8_0`	Gemma 4 12B（本地）	草稿生成
`qwen3.5:9b-q8_0`	Qwen 3.5 9B（本地）	通用任务

> **注意**：`deploy/deer-flow-pacgate/config.yaml`（云路由 deepseek-v4、qwen3.8:27b、gemma4:26b）是**开发/CI 参考**，并非客户 AIPC 运行时使用的配置。客户部署通过 `compose.prod.yaml` 挂载 `deploy/client-bundle/deer-flow-config.yaml`。
>
> **切换模型**：调整 `models` 列表的顺序，把优先模型放在最前。所有模型使用 `api_key: ollama` 与 `base_url: http://host.docker.internal:11434/v1`。

3.4 记忆后端

```
memory:
  storage_class: pacgate_deerflow_adapter.storage.PacgateMemoryStorage
```

`PacgateMemoryStorage` 需要 `PACGATE_MATTER_ID` 才能绑定到具体案件。若缺失，会**静默回退**到本地文件。这是早期"deer-flow 无法查询法律数据库"的根因之一（见第 6 节排障）。

3.5 关键环境变量

变量	说明
`DEER_FLOW_CONFIG_PATH`	deer-flow 配置路径（`/app/backend/config.yaml`）
`PYTHONPATH`	`/app/adapters:/app/backend`（暴露适配器）
`PACGATE_API_URL`	pacgate-api 地址（`http://pacgate-api:8080`）
`PACGATE_TENANT_ID`	租户 ID（默认 `default-firm`）
`PACGATE_MATTER_ID`	绑定到具体案件（记忆适配器必需）

4. OpenViking：长期记忆通道

4.1 它是什么

OpenViking 是 Pacgate-ai 的**长期记忆**服务。它把跨会话的决策、偏好与工作知识提取为**结构化记忆**，供 AI 在后续会话中语义检索、回忆与复用。它是 MCP 服务器，deer-flow 像消费其他 MCP 一样消费它。

4.2 配置

OpenViking 通过 JSON 配置注入（`OPENVIKING_CONF_CONTENT`）：

```
{
  "server": { "host": "0.0.0.0", "port": 1933, "root_api_key": "<OPENVIKING_ROOT_API_KEY>" },
  "storage": { "workspace": "/app/.openviking/workspace" },
  "embedding": {
    "dense": {
      "provider": "ollama",
      "api_base": "http://host.docker.internal:11434/v1",
      "model": "nomic-embed-text",
      "dimension": 768
    }
  }
}
```

4.3 关键点

- **端口**：`1933`（HTTP，对外暴露）
- **embedding**：使用 Ollama 的 `nomic-embed-text`（768 维）
- **root_api_key**：⚠️ 使用 `OPENVIKING_ROOT_API_KEY`，**不是** `OPENVIKING_API_KEY`（后者是应用密钥）。用错会导致 401，并回滚整个 MCP 工具加载。

4.4 与 pacgate-ai 网关的关系

OpenViking 记忆用于**会话上下文**：决策、偏好、工作知识。**绝不**通过 `ov-remember` 存储案件文件或保密案件材料——那些属于 pacgate 案件存储。

---

5. pacgate-ai 网关（pacgate-api）

5.1 它是什么

pacgate-api 是 Pacgate-ai 的**法律元数据网关**（Rust 实现）。它管理租户、案件、文档、工作流模板，并提供 RAG（向量检索）与法律连接器检索。

5.2 服务表面

服务	端点	说明
认证	`POST /api/auth/login`	登录并返回 JWT
案件	`GET /api/matters`	列出案件
文档	`GET /api/matters/:id/documents`	某案件的文档
工作流	`GET /api/workflows`	列出工作流模板
工作流分类	`GET /api/workflows/categories`	工作流分类
工作流详情	`GET /api/workflows/:id`	单工作流步骤
RAG	`GET /api/kb/search`	内部按案件向量检索
连接器	`GET /api/search`	外部法律数据库检索
连接器列表	`GET /api/search/connectors`	可用法律数据源

5.3 数据模型（数据库迁移）

pacgate-api 的数据库迁移定义了核心表：

- `001_initial_schema.sql`：租户、用户、案件、文档、审计日志
- `002_rag_schema.sql`：RAG/向量存储
- `003_rag_enrichment.sql`：RAG 富化
- `004_data_level.sql`：数据分级
- `004_matter_external_keys.sql`：案件外部键（用于 QM 绑定）

5.4 工作流模板

pacgate-api 的 `GET /api/workflows` 暴露 **222 个法律工作流模板（46 类，含上述 10 类经典示例）**。模板存于 `pacgate-ai/workflows/`，由构建过程迁移入库；`GET /api/workflows?category=&search=` 可按分类或关键词过滤：

分类	工作流	步骤数
contract_review	Contract Review（合同审查）	3
contract_review	Contract Comparison（合同比对）	2
due_diligence	Due Diligence Review（尽调审查）	3
legal_research	Legal Research Memo（法律检索备忘录）	3
tabular_review	Tabular Document Review（表格化文档审查）	3
document_generation	Contract Drafting（合同起草）	2
document_generation	Legal Opinion（法律意见书）	2
compliance	Compliance Check（合规检查）	3
ma	SPA Review（股权收购协议审查）	3
litigation	Discovery Review（证据开示审查）	3

每个模板包含 `steps[]`，形如：

```
{
  "category": "due_diligence",
  "name": "Due Diligence Review",
  "steps": [
    { "name": "List all documents", "tool": "list_documents" },
    { "name": "Extract key terms", "tool": "read_table_cells" },
    { "name": "Generate DD report", "tool": "generate_docx" }
  ]
}
```

5.5 pacgate-mcp 桥

`pacgate-mcp`（FastMCP，端口 8000）向 deer-flow 暴露 **19 个工具**，**deer-flow 永远看不到凭据**（认证在 pacgate-api 内部完成）：

工具	说明
`pacgate_kb_search`	内部按案件 RAG 检索（`GET /api/kb/search`）
`pacgate_connector_search`	外部法律数据库检索（`GET /api/search`）
`pacgate_list_connectors`	列出可用法律数据源连接器
`pacgate_list_matters`	列出当前租户的案件（`GET /api/matters`）
`pacgate_list_documents`	列出某案件的文档（`GET /api/matters/:id/documents`）
`pacgate_read_document`	读取/下载某文档的字节（`GET /api/documents/:id/download`）
`pacgate_upload_document`	将生成的成果回传至某案件（`POST /api/documents`）
`pacgate_list_workflows`	列出工作流模板（`GET /api/workflows`）
`pacgate_get_workflow`	获取某工作流模板的步骤（`GET /api/workflows/:id`）
`pacgate_execute_workflow`	运行某工作流模板（`POST /api/workflows/:id/execute`）
`pacgate_read_memory` / `pacgate_write_memory`	读取/写入某案件的结构化记忆（`GET/POST /api/matters/:id/memory`）
`pacgate_get_workspace`	案件工作区汇总：文档 + OCR 抽取 + RAG 一次取回（`GET /api/matters/:id/workspace`）
`pacgate_convert_document`	文档格式转换与生成（docx/markdown 等，经 OfficeCLI）
`pacgate_ocr_document` / `pacgate_ocr_batch`	单个/批量 OCR 抽取（PaddleOCR）
`pacgate_sanitize_document` / `pacgate_verify_sanitized` / `pacgate_sanitize_text`	脱敏处理与 T1-T4 分级校验

> 新增的工具（案件、文档、工作流）让 deer-flow 不仅能**检索**法律知识，还能**访问文档库**、**读取/写入文件**并**运行预置工作流模板**——消除了之前"deer-flow 只能查询、无法触碰文档与模板"的架构缺口。

它启动时用 `PACGATE_API_EMAIL` / `PACGATE_API_PASSWORD` 登录一次，之后在每次调用时转发 Bearer 令牌。

---

6. 部署

6.1 前置条件

- Docker Desktop（WSL2 后端）
- Ollama（Windows 原生）已拉取模型：`nomic-embed-text` 及法律模型
- Node.js 24+（供 qm 使用，若需）

6.2 镜像

组件	镜像
pacgate-api	`ghcr.io/jzkk720/pacgate-api:0.1.23`
deer-flow	`ghcr.io/jzkk720/deer-flow-pacgate:0.1.23`
deer-flow-frontend	`ghcr.io/jzkk720/deer-flow-frontend-pacgate:0.1.23`
pacgate-mcp	`ghcr.io/jzkk720/pacgate-mcp:0.1.23`
nginx	`nginx:1.27-alpine`
openviking	`ghcr.io/volcengine/openviking`

6.3 启动

```
cd deploy
docker compose -f compose.prod.yaml up -d
```

> ⚠️ **重要**：对 deer-flow 做配置变更时，使用 `docker compose restart deer-flow`，**不要**用 `--force-recreate`。deer-flow 的 SQLite 数据库、管理员、线程与 `.jwt_secret` 位于容器内部 `/app/backend/.deer-flow/`（未挂载），重建容器会丢失它们，导致前端 401 并出现 `/setup` 页面。

6.4 验证

```
# 健康检查
curl http://localhost:8089/health

# pacgate-api 登录（获得 JWT）
$body = @{email="admin@pacgate-law.com"; password="<password>"} | ConvertTo-Json
Invoke-RestMethod -Uri "http://localhost:8089/pacgate/api/auth/login" -Method POST -Body $body

# 列出工作流模板
Invoke-RestMethod -Uri "http://localhost:8089/pacgate/api/workflows"
```

---

7. 排障（常见问题）

7.1 deer-flow 无法查询法律数据库

症状：deer-flow 检索不到法律数据库内容。 **根因**：没有工具接入 pacgate-api 的 `/api/kb/search`（RAG）或 `/api/search`（法律连接器）；记忆适配器静默回退到本地文件（`PacgateMemoryStorage` 需要 `PACGATE_MATTER_ID`）。 **修复**：确认 `pacgate-mcp` 已注册，并设置 `PACGATE_MATTER_ID`。

7.2 OpenViking 返回 401，所有 MCP 工具消失

症状：所有 MCP 工具都不出现。 **根因**：deer-flow 用 `asyncio.gather` 加载 MCP，某个服务器 401（错误 API 密钥）会回滚**整个**加载。openviking 的 `root_api_key` 是 `OPENVIKING_ROOT_API_KEY`，不是应用密钥 `OPENVIKING_API_KEY`。 **修复**：使用 `OPENVIKING_ROOT_API_KEY`。

7.3 重建 deer-flow 后出现 `/setup` 页面

症状：前端 401，显示 `/setup`。 **根因**：`docker compose up -d --force-recreate deer-flow` 清空了容器内的本地数据库。 **修复**：用 `docker compose restart deer-flow`；只有接受丢失本地数据库时才重建（然后重跑 `/setup`）。

7.4 模型返回 401 "Incorrect API key"

症状：`ollama-local` 或 `ollama` 被当作真实 API 密钥，请求打到真实 `api.openai.com`。 **根因**：模型配置把 `api_key` 设为 `ollama`，但 base_url 指向 Ollama；若 base_url 缺失或模型路由到了真实 OpenAI，则 401。 **修复**：确认 `base_url: http://host.docker.internal:11434/v1`，且模型为 `*-cloud` 或本地标签。

---

8. 安全与隐私

- **数据边界**：案件文件、检索历史保存在本机 AI 计算机上；对话文本经由已启用的 AI 模型服务处理，文件本身**绝不**上传。
- **凭据**：`PACGATE_API_EMAIL` / `PACGATE_API_PASSWORD`、`OPENVIKING_ROOT_API_KEY` 等存于 `.env`（gitignored）。**不要**提交到仓库。
- **红线**：AI 输出均为律师复核前的草稿，绝不构成最终法律意见。

> 本手册由 pacgate-ai 部署文档与运行环境自动整理生成。版本 0.2.0 — 2026-10-05 (Pacgate-ai v0.1.23)。