

Step 5 本地复杂推理 —— 评测方案模板

目的: 用数据回答一个决定成本结构的问题——本地 **Main(Nemotron3:33b)** 跑中国法 **NDA**/合同复杂风险分级, 是否够好到让 **Step 5** 大部分时候不升级云端? 产出: 一个可重复执行的评测, 输出"本地够用率"和"升级阈值", 供路由器轴 A 调参。配套: 《百宸NDA审查Skill_三层混合云架构改造.md》。

一、为什么需要它

"效果够好"目前是感觉, 不是决策依据。三层架构的省钱逻辑全压在 Step 5:

- 若本地 Main 接近云端 → Step 5 默认本地、云端兜底 → 省 **token** 成立。
- 若差距大 → 高风险事项必须保留云端升级 → 成本回升, 需重新算账。

这个评测把"够不够好"变成一个有阈值、可判定的结论。

二、被测对象(至少 3 条, 建议 5 条)

代号	模型	法域	角色
LOCAL-MAIN	Nemotron3:33b(本地)	—	候选主力
LOCAL-MID	Qwen3.6:27b(本地)	—	降级备选(看 Mid 能否兜部分)
CLOUD-CN	DeepSeek-V4 / Qwen3.6(境内云)	境内	合规可用的云端上限
CLOUD-INTL	Claude Sonnet 4.6 / GPT-5.4(境外云)	境外	质量天花板(仅评测用脱敏数据)
(可选) 人类	百宸律师二审	—	一致性上界参照

注: CLOUD-INTL 仅作质量参照基准, 评测数据必须是已脱敏样本; 不代表生产可用境外云。

三、金标准数据集

规模:起步 50 份, 目标 100–150 份 NDA/商业合同(覆盖单/双向、中外主体、不同行业、含"陷阱"样本)。

标注:每份由 ≥ 2 名百宸律师独立标注, 分歧由第三人裁定, 形成 gold label:

1. 整体分级: GREEN / YELLOW / RED。
2. 问题清单: 每个应识别的问题(如"缺独立开发例外""永久保密""内嵌挖角条款"), 含条款定位。
3. 修改话术(可选): 律师认可的改法, 用于评 Step 5 输出的可用性。

脱敏: 全部先过 Step 2 去标识化关卡, 确保 CLOUD 被测项收到的是脱敏包(同时也顺带验证了去标识化质量)。

版本化: 数据集打 tag 存档, 法规更新后可重跑回归。

四、评测指标

1. 风险分级一致性(最关键)

- 准确率: 模型分级 = gold 分级的比例。
- 危险错误率(重点盯): 把 gold=RED 判成 GREEN/YELLOW 的比例 = 漏报高风险。法律场景下这是最致命指标, 单独设红线(如 $\leq 2\%$)。
- 用混淆矩阵呈现, 不只看总准确率。

2. 问题识别召回率 / 精确率

- 召回: gold 问题被识别的比例(漏报 = 风险)。
- 精确: 识别出的问题中真问题的比例(虚报 = 浪费律师时间)。
- 法律上召回优先于精确——宁可多报让律师删, 不可漏报。

3. 修改建议可用性(人评, 抽样)

- 律师对 Step 5 给的修改话术打分: 直接可用 / 小改可用 / 不可用。

4. 置信度校准(决定升级阈值能不能用)

- 让本地 Main 对每次分级输出一个置信度, 画可靠性曲线: 低置信时是否真的更易错?
- 校准好 $\rightarrow$ 可用"低置信 $\rightarrow$ 升级"省钱; 校准差 $\rightarrow$ 升级触发器失效, 需改用规则触发。

5. 成本/延迟(旁证)

- 每条样本的本地耗时 vs 云端 token 成本, 估算不同阈值下的月度成本。

五、判定规则与阈值

本地够用的判定(示例, 百宸据风险偏好定):

- 危险错误率(RED→低估): $\text{LOCAL-MAIN} \leq 2\%$ 且不显著高于 CLOUD-CN;
- 整体分级准确率: $\text{LOCAL-MAIN} \geq \text{CLOUD-CN} - 5\text{pp}$;
- 问题召回率: $\text{LOCAL-MAIN} \geq 85\%$ 。
- 满足 → **Step 5** 默认本地; 不满足 → 见下。

升级阈值的产出(路由器轴 **A** 用):

- 若置信度校准良好: 定一个置信阈值 τ , 本地分级置信 $< \tau \rightarrow$ 升级境内云。在评测集上调 τ , 使"升级后危险错误率达标"且"升级比例最小"。
- 若校准差: 改规则触发——高风险信号(金额、RED 倾向、新型条款、法源冲突)强制升级, 与置信度无关。
- 硬规则(不可调): gold 维度里属高风险类目的事项, 一律强制升级(云或人), 不靠模型自评。

六、执行流程

1. 建集: 50→100+ 样本, 双标注 + 裁定, 过 Step 2 脱敏。
2. 跑测: 同一脱敏输入喂 5 个被测项, 固定 prompt/温度, 各出分级+问题+置信度。
3. 计分: 脚本算混淆矩阵、召回/精确、校准曲线、成本。
4. 抽样人评: 律师评修改话术可用性。
5. 判定: 对照第五节阈值, 出结论 = {Step5 默认本地 / 默认境内云 / 混合阈值 τ }。
6. 归档 + 回归: 数据集与结果版本化; 模型或法规更新后重跑。

七、复用

同一套方法换 gold 维度即可评其他 skill 的复杂推理步: 合同审查、隐私 DPA 审查、劳动解雇审查。每条 **skill** 线都应有自己的金标准集与本地够用判定, 不可用 NDA 的结论替代。

八、待百宸决策

1. 危险错误率红线定多少(2%?1%?)——直接决定多少事项被迫升级。
2. 金标准标注由哪几位律师负责、裁定人是谁。
3. 起步样本量与覆盖面(行业/单双向/涉外比例)。
4. 是否纳入 CLOUD-INTL 作天花板参照(涉脱敏数据出境,需合规确认)。