

百宸 NDA / 合同审查 Skill —— 三层 LLM + 混合云架构改造

用途:把 Claude for Legal 的 NDA 审查 skill, 改造为适配百宸"三层本地 LLM 路由器 + BYOK 混合云"架构。供律师、工程与 Codex 对齐 skill 设计、路由逻辑与数据流。
状态:正式版 v0.2(蓝本:原版 [commercial-legal:review \(nda-review\) / triage-nda](#))。配套:评测方案见《Step5_本地复杂推理_评测方案模板.md》。红线:本 skill 任何输出均为供律师复核的草稿, 非最终法律意见。

一、设计前提:三层 LLM 路由器

Tier	本地模型	BYOK 云端	云端法域
Main(最强)	Nemotron3:33b	Claude Sonnet 4.6 / GPT-5.4	境外
Mid	Qwen3.6:27b	DeepSeek-V4 / Qwen3.6	境内
Low	Qwen3.5:9b	MiniMax-2.7	境内

成本目标:本地能扛则本地扛, 最低限度调用云端, 省 token 与费用。

二、路由三轴(核心:别把三件事混成一件)

省钱靠的是轴 A, 图里原本只画了 B 和 C。三轴必须分开实现:

轴 A —— 复杂度/风险路由(决定省不省钱)

按任务复杂度与风险, 路由到够用的最低 tier, 而非默认 Main。

- 例行/确定性任务(识别、抽取、格式化)→ Low
- 中等任务(去标识化、查询编排、起草)→ Mid
- 复杂推理(逐条对照、风险分级) → Main

 反转提醒:原图"降级链"默认走 Main 最贵。省钱要求默认走够用的最低 tier, 复杂时才升级——方向与降级链相反。

轴 B —— 本地 / 境内云 / 境外云 (决定合规)

数据敏感度门禁不是"本地 vs 云端"二档, 而是三档:

数据类型	允许去向
客户敏感数据 (合同原文、当事人、案件事实、内部库)	仅本地
去标识化中间表示 + 内部 playbook	本地 / 境内云
纯公开法源 / 抽象法律问题 (零客户信息)	本地 / 境内云 / 境外云

每个 BYOK provider 打法域标签 (境内/境外), 路由器据此 gate。

轴 C —— 风险感知降级 (决定容灾不牺牲质量)

图里的 Main 不可用 → Mid → Low 是可用性容灾, 但在法律里不能静默降级:

- 低风险任务: Main 挂 → 静默退 Mid/Low, 正常。
- 高风险任务: Main 挂 → 排队 / 告警 / 转人工, 禁止静默退到 9b。

三、为什么要把 skill 拆成多步: 敏感与复杂在法律里高度重叠

一份客户合同的交叉风险分析, 既复杂 (该上 Main) 又满含客户隐私 (该留本地)。解法不是二选一, 而是把单 skill 拆成多步, 在步骤间设去标识化关卡: 客户数据在本地处理, 过关卡后只把"脱敏包 + 公开法源"交给 Main (本地优先, 必要时境内云), 结果再回本地套回客户语境。

三层本地的红利: 去标识化关卡只在上云那一跳才需要。任务在三层本地之间流动时数据全程不出本地、无需脱敏。本地扛得越多 → 省 token + 省合规开销, 收益叠加。

四、NDA 审查 Skill —— 完整流程 (8 步 × 三轴标签)

[Low/本地] 0 任务识别·涉外前置

└─> [Low-Mid/本地] 1 接收·解析·要素抽取 (客户敏感)

└─> [Mid/本地·关卡] 2 去标识化 ★ 合规枢纽 (客户敏感→去标识化)

└─>[Low/本地] 3 载入百宸 playbook

└─>[Low-Mid/本地] 4 法源核验: 北大法宝/元典 MCP (公开法源·查询须脱敏)

└─>[Main/本地] 5 复杂推理·逐条对照·风险分级 (去标识化+公开法源)

└─>[Mid/本地] 6 回填客户语境·生成中文交付稿 (客户敏感)

└─>[Low/本地+人工] 7 律师复核·来源分级·声明

#	步骤	tier(默认)	data	何时升级云 / 备注	人工关卡
0	任务识别·涉外前置(识别独立NDA;适用法/管辖/语言/冲突规则,默认中国法)	Low 本地	客户敏感	基本不需要	—
1	接收·解析·要素抽取(当事人/单双向/定义/义务/例外/期限/救济/管辖)	Low-Mid 本地	客户敏感	长难合同→Mid;不上云	—
2	去标识化关卡★(当事人→[甲][乙],抹除可识别信息,保留条款措辞;映射存本地审计日志)	Mid 本地+规则	客户敏感→去标识化	不上云	✓
3	载入百宸 playbook(期限/必备条款/竞业挖角口径/可接受管辖/升级阈值)	Low 本地	内部	确认无客户信息可随脱敏包去境内云	—

#	步骤	tier(默认)	data	何时升级云 / 备注	人工关卡
4	法源核验 MCP(竞业→劳动合同法23/24;商业秘密→反不正当竞争法、民法典;期限合理性)	Low-Mid 本地	公开法源	查询串须用脱敏文本	—
5	复杂推理·风险分级(逐条对照playbook, GREEN/YELLOW/RED, 给修改话术)	Main 本地 (Nemotron3 3b)	去标识化+公开法源	低置信+高风险→境内云 (DeepSeek/Qwen); 仅零客户信息可境外	—
6	回填客户语境·生成中文交付稿(律师审查意见/客户版摘要/内部风险memo)	Mid 本地	客户敏感	不上云	—
7	律师复核·来源分级·声明(标注:经权威法源核验/元典辅助/内部模板/模型推断+复核声明+路由建议)	Low 本地+人工	客户敏感	—	✓

唯一可能需要云端的是 **Step 5**。省钱成败压在一个问题上：**Nemotron-33b** 本地跑中国法 **NDA** 复杂风险分级，够不够好到让 **Step 5** 大部分时候不升级？→ 用评测方案验证。

五、路由器须实现的护栏(系统级, 非临时提醒)

- 1. data: 客户敏感 的步骤 → tier 必须为本地, 禁止任何云端。
- 2. 任何上云步骤, 输入只能是去标识化或公开法源; 上游无去标识化关卡则拒绝执行。
- 3. 去标识化关卡本地执行 + 人工/规则确认 + 审计日志(记录抹除了什么、映射关系)。
- 4. 境外云(Claude/GPT)仅对"零客户信息"开放; 去标识化包默认只允许本地或境内云。
- 5. 高风险事项的可用性降级 = 排队/告警/转人工, 禁止静默退到低 tier。
- 6. 升级触发器 = 置信度信号 + 风险标记; 高风险无论本地置信多高都强制升级(云或人)。

六、合规要点(律所自身风险)

- 数据出境: Step 5 若用境外云, 即便脱敏仍可能触发《个人信息保护法》《数据安全法》出境要求及律师保密义务。默认境内云; 具体阈值请合规口按现行规定核定。
- 去标识化质量: Step 2 是合规单点。建议双保险——规则引擎确定性抹除(正则/实体词典) + Mid 本地模型补漏 + 抽样人工校验。
- 法源时效: 北大法宝/元典随调随用; 元典(IMA)为辅助线索库, 不单独作为最终依据。

七、与原版 Claude for Legal 的差异

维度	原版	百宸三层混合云版
模型假设	单一 Claude	三层本地 + BYOK 混合云, 按轴 A 路由
路由标签	无	tier / data / 法域 / 人工关卡 / 升级触发
去标识化关卡	无	新增 Step 2 合规枢纽
数据门禁	无	三档: 本地 / 境内云 / 境外云
法域	美国法	中国法默认 + 涉外前置
实体判断	英美口径	劳动合同法/反不正当竞争法/民法典重写
法源	Westlaw/CourtListener	北大法宝 + 元典 MCP

维度	原版	百宸三层混合云版
输出	英文报告	中文三件套 + 来源分级 + 复核声明

八、待百宸决策 / 待确认

- 1. **Step 5** 评测: Nemotron33b 本地是否够好到让复杂推理默认本地? (见评测方案)
- 2. 本地上下文/显存: 长合同+脱敏包+playbook 对 Main 本地的上下文长度要求?
- 3. 去标识化人工关卡形态: 每单必审 vs 按金额/敏感度抽审?
- 4. 法源 **MCP** 隔离等级: 是否需供应商私有化部署版?
- 5. 境外云使用边界: 是否完全禁用境外云于任何含(即便脱敏)客户信息的任务?

下一步: 本正式版确认后 → (a)落地可在 *Claude Code* 跑的 *NDA skill* 原型; (b)把 8 步×三轴模板复用到合同审查、隐私 *DPA*、劳动解雇等 *skill*; (c)执行 *Step 5* 评测, 定升级阈值。