

# 百宸 NDA / 合同审查 Skill —— 双模型架构改造示范

用途: 把 Claude for Legal 的 NDA 审查 skill, 改造为适配百宸"本地模型处理敏感数据 + 云端模型做复杂推理"的混合架构。供律师、工程与 Codex 对齐 skill 设计与数据流。状态: 示范稿 (v0.1), 以原版 `commercial-legal:review (nda-review) / triage-nda` 工作流为蓝本。红线: 本 skill 任何输出均为供律师复核的草稿, 非最终法律意见。

## 一、为什么要重拆: 法律任务里"敏感"与"复杂"高度重叠

简单的"敏感走本地、复杂走云端"二分在法律场景失效——一份客户合同的交叉风险分析, 既复杂(该上云)又满含客户隐私与特权信息(该留本地)。

解决办法不是按任务二选一, 而是把单个 **skill** 拆成多步, 在步骤之间设一个去标识化关卡 (**de-identification gate**): 客户敏感数据在本地处理, 过关卡后只把"脱敏中间表示 + 公开法源"送上云做推理, 云端结果再回到本地套回客户语境。

三类数据的路由方式本就不同:

| 数据类型              | 例子                           | 默认路由                 |
|-------------------|------------------------------|----------------------|
| 客户敏感数据            | 合同原文、当事人身份、案件事实、内部台账、IMA 内部库 | 本地模型                 |
| 公开法源              | 北大法宝 / 元典的法条、案例              | 任一层可调(查询串若含客户信息须先脱敏) |
| 去标识化中间表示 / 抽象法律问题 | 脱敏后的条款文本、事实模式、纯法律论证          | 云端模型(优先境内云)          |

## 二、路由标签规范(可复用于所有 skill)

每个 skill 步骤都打三个标签。这是原版 Claude for Legal 没有、百宸版必须新增的设计层(原版假设只有 Claude 一个模型)。

step:

tier: local | cloud | gate      # 在哪执行:本地模型 / 云端模型 / 去标识化关卡

data: client-sensitive | public-law | de-identified | internal

# 这一步接触的数据类型

rationale: "为什么放这一层"

human\_gate: true | false      # 是否需要人工/规则确认后才能继续

约束规则(写进系统级护栏) :

1. **data: client-sensitive** 的步骤, **tier** 必须为 **local**。客户敏感数据不出本地。
2. 任何 **tier: cloud** 的步骤, 输入只能是 **de-identified** 或 **public-law**。上云前必须先过 **gate**。
3. **gate** 步骤本地执行, 建议 **human\_gate: true**(或强规则校验), 并记录"抹掉了什么"到审计日志。
4. **internal**(百宸 **playbook**/口径)默认 **local**;若确认不含客户与个人信息, 可随脱敏包上云, 但需显式标注。

---

### 三、NDA 审查 Skill —— 双模型流程(8 步)

[本地] 0 任务识别·涉外前置

└─> [本地] 1 接收·解析·要素抽取      (客户敏感)

└─> [关卡] 2 去标识化 ★ 合规枢纽      (客户敏感 → 去标识化)

└─> [本地/内部] 3 载入百宸 **playbook**

└─> [MCP] 4 法源核验: 北大法宝/元典      (公开法源·查询须脱敏)

└─> [云端] 5 复杂推理·逐条对照·风险分级 (去标识化+公开法源)

└─> [本地] 6 回填客户语境·生成中文交付稿 (客户敏感)

└─> [本地+人工] 7 律师复核关卡·来源分级·声明

## Step 0 — 任务识别 & 涉外前置判断 `tier: local · data: client-sensitive`

- 判断文件是否为独立 NDA(非嵌入 MSA 的保密条款)。
- 涉外前置(原版没有, 百宸新增): 识别当事人国籍/注册地、适用法、管辖、语言版本、冲突规则假设。默认中国法; 涉外则显式标注假设。
- 为什么本地: 要读合同正文, 属客户敏感数据。任务轻, 本地模型足以做分类与抽取。

## Step 1 — 接收·解析·要素抽取 `tier: local · data: client-sensitive`

- 解析文档(含 OCR), 抽取: 当事人、单/双向、保密信息定义、义务、例外(carveouts)、期限、返还销毁、救济、管辖。
- 输出结构化要素表(仍含客户身份)。
- 为什么本地: 原始文档全程不出本地。

## Step 2 — 去标识化关卡 ★ `tier: gate · data: client-sensitive → de-identified · human_gate: true`

整条流程的合规枢纽。

- 把当事人名 → [甲方]/[乙方], 抹除可识别信息(项目名、金额、人名、地址、联系方式), 保留法律结构与条款原文措辞。
- 产出"脱敏审查包": 条款文本 + 要素结构, 零客户标识。
- 记录映射关系(真实身份 ↔ 占位符)到本地审计日志, 仅 Step 6 回填时本地读取。
- 人工/规则确认通过后, 方可进入上云步骤。
- 为什么是关卡: 这是"敏感留本地、复杂上云"得以成立的唯一技术保证。质量直接决定合规风险。

## Step 3 — 载入百宸 playbook(practice profile) `tier: local · data: internal`

- 从百宸 `CLAUDE.md` 读取 NDA 立场: 可接受期限、必备/可让步条款、竞业与挖角口径、可接受管辖、升级阈值。
- 为什么本地/内部: house 口径属内部资产; 如确认不含客户信息, 可随脱敏包上云供 Step 5 使用。

## Step 4 — 法源核验: 北大法宝 / 元典 MCP `tier: mcp · data: public-law`

- 对每个中国法判断点触发检索, 例如:
  - 竞业限制 → 《劳动合同法》第 23/24 条及经济补偿规则、相关案例

- 商业秘密 → 《反不正当竞争法》、《民法典》合同编保密义务
- 保密期限合理性 → 行业惯例与裁判口径
- 语料公开，本地或云端均可发起调用；但查询串必须用 **Step 2** 的脱敏文本，不得含客户信息。
- 返回结果带来源，供 Step 5 引用并在 Step 7 标注。
- 注：北大法宝/元典 MCP 为供应商官方提供、已在 Claude Code 跑通。若百宸走更高隔离等级，需向供应商确认是否有私有化/本地部署版。

Step 5 — 复杂法律推理·逐条对照·风险分级 **tier: cloud · data: de-identified + public-law**

- 输入：脱敏审查包 + 百宸 playbook + 法源核验结果。不含任何客户标识。
- 做深度分析：逐条对照 playbook、识别问题、按中国法重写后的标准做 **GREEN / YELLOW / RED** 分级、给具体修改话术。
- 为什么云端：这是最吃模型能力的复杂推理；输入已脱敏 + 公开法源，可安全上云。
- 合规优先选境内云（如通义千问 Max 等境内 API）。境外模型仅限完全不含客户信息的场景，且须先过数据出境合规（见第五节）。

Step 6 — 回填客户语境·生成中文交付稿 **tier: local · data: client-sensitive**

- 用 Step 2 的映射，把云端结果里的 [甲方]/[乙方] 等占位符回填为真实当事人。
- 生成百宸固定中文格式：① 律师审查意见 ② 客户版摘要 ③ 内部风险 memo。
- 为什么本地：输出重新含客户标识，必须回到本地。

Step 7 — 律师复核关卡·来源分级·声明 **tier: local · data: client-sensitive · human\_gate: true**

- 对每条结论标注来源等级：经权威法源核验 / 来自元典(IMA)辅助 / 来自内部模板 / 模型推断。
- 附固定声明：本输出为律师审阅草稿，不构成最终法律意见；所有法条、案例、监管依据应由执业律师在正式交付前复核。
- 路由建议（GREEN 同日批准 / YELLOW 指定复核 / RED 不签、反提案）。

四、步骤路由总表

| # | 步骤        | tier  | data             | 人工关卡 | 谁主导               |
|---|-----------|-------|------------------|------|-------------------|
| 0 | 任务识别·涉外前置 | local | client-sensitive | —    | 工程(规则)+<br>律师(口径) |

| # | 步骤            | tier           | data                     | 人工关卡 | 谁主导         |
|---|---------------|----------------|--------------------------|------|-------------|
| 1 | 接收·解析·要素抽取    | local          | client-sensitive         | —    | 工程          |
| 2 | 去标识化关卡★       | gate           | client→de-identified     | ✓    | 工程+合规       |
| 3 | 载入百宸playbook  | local/internal | internal                 | —    | 律师          |
| 4 | 法源核验(北大法宝/元典) | mcp            | public-law               | —    | 工程接线+律师定规则  |
| 5 | 复杂推理·风险分级     | cloud          | de-identified+public-law | —    | 律师(判断规则)+工程 |
| 6 | 回填·生成中文交付稿    | local          | client-sensitive         | —    | 工程+律师(格式)   |
| 7 | 律师复核·来源分级·声明  | local          | client-sensitive         | ✓    | 律师          |

---

## 五、合规要点(律所自身风险, 须前置)

1. 数据出境: 若 Step 5 用境外云端模型, 即便脱敏, 仍可能触发《个人信息保护法》《数据安全法》的数据出境要求及律师执业保密义务。建议复杂推理默认境内云; 境外模型仅用于零客户信息场景。具体出境阈值与口径请合规口按现行规定核定。
  2. 去标识化质量: Step 2 是合规成败的单点。建议双保险——规则引擎做确定性抹除(正则/实体词典)+本地模型补漏+抽样人工校验, 并保留审计日志。
  3. 关卡不可绕过: 系统级强制——tier: cloud 的步骤若上游无 gate, 直接拒绝执行。
  4. 法源时效: 北大法宝/元典返回内容随调随用; 元典(IMA)定位为辅助线索库, 不单独作为最终依据。
-

六、与原版 Claude for Legal 的差异

|        |                                      |                                      |
|--------|--------------------------------------|--------------------------------------|
| 维度     | 原版 (triage-nda /<br>nda-review)      | 百宸双模型版                               |
| 模型假设   | 单一模型(Claude)                         | 本地+云端双模型，步骤分层                        |
| 路由标签   | 无                                    | 新增<br>tier/data/rationale/human_gate |
| 去标识化关卡 | 无                                    | 新增 Step 2, 合规枢纽                      |
| 法域     | 美国法、美国市场惯例                           | 中国法默认 + 涉外前置                         |
| 实体判断   | carveout 清单、禁<br>non-compete 等(英美口径) | 按《劳动合同法》《反不正当竞争法》《民法典》重写             |
| 法源     | Westlaw/CourtListener                | 北大法宝 + 元典 MCP                        |
| 输出     | 英文报告                                 | 中文三件套 + 来源分级 + 复核声明                  |

七、待百宸决策 / 待确认

- 1. 境内云端模型选型: 复杂推理用哪个境内 API(通义千问 Max / 其他)? 需实测中文法律推理质量。
- 2. 本地模型上下文长度: 长合同 + 脱敏包 + playbook 的本地处理, 对上下文与显存的要求? 决定本地模型规格。
- 3. 去标识化的人工关卡形态: 每单必审, 还是按金额/敏感度抽审?
- 4. 法源 MCP 隔离等级: 是否需要供应商私有化部署版(取决于最终私有化等级)。
- 5. Step 5 上云边界: playbook 是否允许随脱敏包上云, 还是只发条款文本?

下一步建议: 本示范确认后, 可据此 (a) 落地一个可在 Claude Code 跑的 NDA skill 原型 (Step 2 去标识化先用规则+本地模型占位), (b) 再把同一套 8 步骤模板套用到合同审查、隐私 DPA、劳动解雇等其他 skill。