

Pacgate AI Phase 1 技术方书面澄清问题清单

- 适用对象：Cubeccloud / 技术支持团队书面回复
- 项目：Pacgate AI Law Firm Phase 1 本地试点
- 版本：v1.0
- 来源：docs/assets/q&a/Pacgate_AI_Phase1_■■■■■■■■■■■■■■■■■■■■.docx
- 用途：临时澄清工作底稿，不属于公开 proposal index 或 onboarding surface

回复要求

请贵方按以下问题逐项书面回复，并在每项回复中明确标注：

1. 已包含在 Phase 1 固定交付范围内
2. 可通过顾问小时支持
3. 需另行报价
4. 暂不支持
5. 待双方进一步确认

如涉及硬件、软件授权、开源项目、数据流、第三方服务、验收标准或后续 SaaS 化，请尽量提供具体配置、路径、预算区间、交付物和责任边界。

一、项目定位与总体交付边界

1. 请确认本次 Phase 1 的性质是“本地 AI 试点与开源法律 AI 项目部署支持”，而不是完整 Pacgate SaaS 平台建设。
2. 请确认 Phase 1 是否包含任何面向外部客户的正式 SaaS 产品开发、客户门户、多租户系统或商业化平台建设。
3. 请确认 Phase 1 同时验证两个方向：系统 1 为 Pacgate 内部律师效率工具；系统 2 为基于 Lavern agent teams 的未来商品化 / SaaS 化主线。
4. 请明确 Phase 1 结束时，Pacgate 实际能获得哪些可运行系统、文件、账号、配置、代码仓库、部署文档和操作手册。
5. 请明确哪些工作属于固定交付范围，哪些工作需要进入 Package 4 顾问小时或另行报价。
6. 请说明本次 Phase 1 的核心成功标准是什么：硬件可用、律师内部使用、Lavern 原型跑通、客户内测可行，还是其他标准。
7. 请说明 Phase 1 中两套系统之间的关系：是两个独立试验环境，还是未来会合并为一个统一 Pacgate AI 系统。
8. 请说明贵方认为 Phase 1 中哪些成果可以直接沉淀为 Phase 2 SaaS 化资产，哪些只是试验性或一次性工作。

二、硬件采购、配置与扩展路线

1. 目前方案是否确定为采购两台独立硬件设备？这两台设备分别承担什么角色，是一主一备、两套并行试验环境，还是分别用于 Claude for Legal 与 Lavern 两个开源项目？

2. 这两台设备是否是专门为 Phase 1 试点配置的硬件？请说明它们的设计目标是“学习和验证”还是“未来生产 / 商业化可延续使用”。
3. 请提供两套 AIPC 设备的完整 BOM，包括主机型号、CPU、内存容量、存储容量、网卡、接口、操作系统。
4. 请提供外接 GPU Dock 与显卡的完整规格，包括 Dock 型号、连接方式、Thunderbolt 版本、显卡型号、显存容量、功耗和散热方案。
5. 请评估当前两台 AIPC 级设备的算力、内存、显存、存储和带宽是否足以支持 Phase 1 需求，包括本地模型推理、RAG 检索、文档解析、两个开源法律 AI 项目运行、律师日常使用和基础自动化工作流。
6. 请说明该硬件配置可稳定运行哪些本地模型，例如 7B、14B、32B、70B 参数级模型，以及对应的量化方式、推理速度和并发能力。
7. 请明确当前硬件配置在 Phase 1 中的能力上限，例如最多支持多少名律师同时使用、可处理多大文件、可运行哪些模型、平均响应速度是多少。
8. 请说明本地模型默认使用哪些框架或工具运行，例如 Ollama、vLLM、llama.cpp 或其他方案。
9. 请说明两台设备是否都能独立运行，还是需要互相依赖或依赖 CUBEcloud 云端控制平面。
10. 如果 Phase 1 成功并进入 Phase 2，当前两台设备是否仍可继续作为生产环境使用？还是只能作为开发、测试、演示或备用节点？
11. 若 Phase 2 要支持更多律师、更多客户事项、更复杂的 RAG、agent workflow 和商业化交付，是否需要另行采购更高性能的服务器，例如 NVIDIA GPU 工作站或服务器？
12. 如果需要 Phase 2 服务器，请提供推荐配置和预算区间，包括 GPU 型号、显存、CPU、内存、存储、网络、机箱、电源、散热，以及预估总价。
13. 请比较两种路线的优劣和总成本：路线 A 为 Phase 1 先买两台 AIPC 小型设备，Phase 2 再另买高性能服务器；路线 B 为 Phase 1 直接采购一台更高性能、更可延续使用的 NVIDIA / AI 工作站或服务器。
14. 从技术和成本角度看，贵方是否建议我们现在购买两台 AIPC 设备，还是直接换成一台更高能效、更适合未来商业化扩展的硬件？请给出理由。
15. 如果现在购买两台 AIPC 设备，未来升级到更高性能服务器时，模型、知识库、向量库、workflow、配置和数据是否可以无损迁移？迁移工作是否包含在 Phase 1 或顾问支持中？
16. 请说明当前两台设备未来可否作为 Phase 2 架构中的边缘节点、律师工作站、备份节点或开发测试节点继续使用，避免硬件闲置。
17. 请提供至少两个替代硬件方案供 Pacgate 比较：方案一为当前两台 AIPC 方案；方案二为一台更高性能工作站 / 服务器方案；如可行，请再提供方案三：利用 Pacgate 现有 Mac Studio 或自购服务器部署的轻资产方案。
18. 请分别列出上述方案的一次性采购成本、部署成本、预计可使用年限、可支持用户数、可运行模型级别和未来扩展方式。
19. 请说明硬件售后、保修、维修、更换、系统重装、显卡故障和数据迁移责任分别由谁承担。
20. 请说明如果硬件性能无法达到 Phase 1 约定验收标准，贵方是否负责升级、更换或调整配置。

三、硬件交付、部署地点与数据流

1. 两套硬件设备最终是直接邮寄到 Pacgate 北京办公室，还是先放在 CUBEcloud 深圳办公室完成部署、测试后再寄送？

2. 如果设备先在 Cubeccloud 处部署，请说明部署期间 Pacgate 是否可以远程查看、测试和验收。
3. 设备交付到北京办公室后，是否需要 Pacgate 自行完成网络、电源、显示器、路由器、防火墙、远程访问等配置？Cubeccloud 是否提供远程协助？
4. Phase 1 调试期间，我们是直接远程连接到自己购买的本地硬件进行调试，还是通过 Cubeccloud 云平台进行调试？
5. 如果通过 Cubeccloud 云平台调试，请说明数据、文件、日志、模型输入输出是否会经过或存储在 Cubeccloud 云端。
6. 请明确“本地部署”的数据流：客户文件、律师上传材料、prompt、模型输出、RAG 索引、日志，分别存储在哪里？
7. 如果所有数据最终同步到 Pacgate 自购硬件，请说明同步机制、延迟、失败处理和数据一致性保障。
8. 如果北京办公室网络断开，系统是否仍可在本地继续运行？哪些功能会受影响？
9. Cubeccloud 是否需要长期保留远程管理员权限？如需要，请说明权限范围、审计方式、关闭方式和安全责任。
10. 硬件到 Pacgate 后，是否支持 Pacgate 技术人员或指定律师直接登录后台、查看配置、修改 prompt、运行脚本和调试系统？

四、Cubeccloud Agent OS 与本地 AI 基础层

1. 请列明 Phase 1 中实际启用的 Cubeccloud 组件：OpenSpace、Open WebUI、IronClaw、Hermes、Warp ADE、OpenCode 各自交付到什么程度。
2. 请分别说明上述组件在 Phase 1 中的具体用途、登录方式、权限管理方式和日常使用场景。
3. 请说明 Cubeccloud Agent OS 是否为 Pacgate 永久授权、年度授权，还是需持续订阅。
4. 如果 Phase 1 结束后 Pacgate 不继续购买 Cubeccloud 服务，已部署系统是否仍可运行？哪些功能会停止或受限？
5. 请说明 Pacgate 是否可以导出全部配置、日志、知识库、向量库、prompt、workflow 和数据文件。
6. 请说明 Cubeccloud 专有组件与开源组件之间的边界，哪些部分未来可以独立迁移，哪些部分依赖 Cubeccloud 平台。

五、系统 1：内部律师使用的 Claude for Legal

1. 请确认系统 1 的定位是 Pacgate 内部律师使用的效率工具，目标是提高律师日常法律研究、文件审查、报告起草和知识检索效率。
2. 请确认本次方案中所称 Claude for Legal 指的是 GitHub 仓库 `anthropics/claude-for-legal`。
3. 请说明贵方对 Claude for Legal 的交付方式：是部署原仓库、fork 到 Pacgate 仓库、配置为 Claude plugin，还是通过 Managed Agents API 使用？
4. 请说明 Claude for Legal 哪些部分可以本地运行，哪些部分必须依赖 Anthropic / Claude 云端服务。
5. 系统 1 是否可以优先部署，让 Pacgate 律师尽早使用？如果可以，预计从 kickoff 到可内部试用需要多久？
6. 系统 1 在调试阶段是否可以开放给 Pacgate 全体律师使用，还是建议只开放给少数负责调试的律师？如建议限制使用人数，请说明原因。
7. 系统 1 支持多少名律师同时使用？请给出推荐用户数、并发上限和性能预期。

8. 律师使用系统 1 的入口是什么？例如网页端、Open WebUI、Claude 插件、本地客户端、飞书、微信、浏览器地址，还是其他方式？
9. 律师是否可以通过自己现有的 Codex、IMA Copilot、Claude Code 或其他 AI 工具接入本地系统？如果可以，需要怎样配置？
10. 系统 1 是否支持律师上传 Word、PDF、合同、法规材料，并输出带引用的审查草稿、备忘录或报告初稿？
11. 系统 1 是否支持每个律师独立账号、权限隔离、历史记录管理和 matter 归档？
12. 系统 1 是否支持 Pacgate 内部知识库、模板、历史文件和个人工作区？
13. 请说明系统 1 在 Phase 1 中的最小验收场景，例如能否基于 Pacgate 的合规材料生成带引用的审查草稿。
14. 请说明贵方负责的是技术部署与运行支持，还是也负责 Pacgate 法律 playbook、practice profile、prompt 和 workflow 的实质适配。

六、系统 2：Lavern Agent Teams 与未来商品化方向

1. 请确认系统 2 的定位是基于 Lavern agent teams 框架，作为未来客户自动化交付、商品化和 SaaS 化的主线。
2. 请确认本次方案中所称 Lavern 指的是 GitHub 仓库 github.com/AnttiHero/lavern 及官网 lavern.ai。
3. 请说明 Lavern 的部署方式：是否 fork 到 Pacgate 仓库，是否在两台本地设备上完整运行，是否使用 Docker 或其他部署方案。
4. 请说明 Lavern 本地模式会使用哪些模型，是否通过 Ollama 运行，是否需要外部 Claude / Mistral API。
5. 请说明 Lavern 的 agent teams、verification loop、human gate 等功能在 Phase 1 中会启用到什么程度。
6. 请说明 Lavern 当前是否被贵方认为是生产级系统、演示型系统，还是可供 Pacgate 学习和二次开发的开源参考系统。
7. 系统 2 是否可以在 Phase 1 中作为“未来商品化原型”搭建，而不是仅作为技术演示？
8. 系统 2 在 Phase 1 中是否能跑通一个最小商业闭环：客户提交材料、agent 访谈或补充问题、自动分析、生成草稿、Pacgate 律师复核、输出交付件？
9. 系统 2 在调试阶段是否可以通过真实入口测试，而不仅仅是在技术后台或命令行中测试？
10. 系统 2 是否可以接入飞书、微信、邮件或网页表单，用于模拟真实客户提交材料、回答问题、补充文件和接收初步输出？
11. 如果 Phase 1 固定交付不包含飞书、微信、邮件入口，请说明各入口的最小可用版本预计需要多少顾问小时。
12. 系统 2 是否可以邀请少量种子客户参与内测？如果可以，请说明所需账号、权限、数据隔离、免责声明和安全配置。
13. 种子客户通过飞书、微信或邮件提交的文件和对话，是否会进入本地硬件、matter 文件夹、RAG 或 Lavern workflow？
14. 系统 2 是否支持“客户提交材料 → agent 自动分析 → 生成草稿 → 律师复核 → 再交付客户”的完整测试流程？
15. 系统 2 是否支持 Human-in-the-loop，即所有输出在发给客户前必须经过 Pacgate 律师审批？
16. 系统 2 在客户内测阶段，是否可以设置为只输出“草稿 / 内部参考”，不自动形成正式法律意见？

17. 请说明系统 2 的最小验收场景，例如上传一份材料后，系统能否完成 evidence / counter-evidence 审查并输出草稿交付件。

七、两个系统之间的数据、知识与 workflow 关系

1. 请说明系统 1 和系统 2 的数据是否互通。例如律师在 Claude for Legal 中形成的知识、prompt、文件或结论，是否可以被 Lavern agent teams 调用，反之亦然。
2. 如果两套系统分别部署在两台设备上，请说明文件、知识库、用户权限和 matter 数据如何同步或隔离。
3. 请说明 Phase 1 中是否会建立统一的 matter 文件结构，使律师内部使用和客户自动化测试都归集到同一事项目录。
4. 请说明在调试阶段，Pacgate 修改 prompt、agent roles、workflow、报告模板时，是通过网页界面修改，还是需要修改代码仓库和配置文件。
5. 请说明 Cubecloud 在调试阶段提供的支持方式：远程会议、共享屏幕、代码仓库协作、问题单、文档说明，还是现场 workshop。
6. 请说明如果 Pacgate 希望每周推进一次真实业务场景测试，例如数据合规、AI 合规、Web3/RWA 合规，Cubecloud 是否可以按顾问小时陪跑。

八、Pacgate 自主适配与分工

1. Pacgate 希望自己主导法律场景、prompt、playbook、agent workflow 和报告模板适配。请确认贵方在这部分的角色是技术支持与陪跑，而不是法律内容交付方。
2. 请明确 Package 2 中“Claude for Legal 适配”“Lavern 适配”“playbook / workflow tailoring”的具体工作内容、交付件和验收标准。
3. 如果 Pacgate 自己进行法律适配，Package 2 是否可以改写为“开源项目部署、运行验证、技术评估与适配陪跑”？
4. 请说明贵方是否可以提供每周固定技术支持会议、问题清单跟踪和代码 / 配置排障支持。
5. 请说明贵方是否负责为两个开源项目提供部署脚本、依赖版本清单、环境变量清单、启动说明和故障排查指南。

九、外部法律数据库 MCP、RAG 与 Context Graph

1. 如果 Pacgate 接入北大法宝、元典等外部法律数据库 MCP，Package 3 是否仍需要导入大量公开法规文本？
2. 贵方建议哪些内容走外部法律数据库 MCP，哪些内容进入 Pacgate 私有 RAG？
3. Phase 1 的 authority registry 是否可以只保存外部法源的引用、版本、链接、检索记录和律师确认结果，而不是复制完整法规库？
4. Pacgate 私有知识库是否应重点存放 playbook、模板、客户材料、历史报告、律师复核意见和 agent 输出？
5. 请说明 Package 3 中 authority registry 的具体字段设计，例如来源、版本日期、效力状态、适用地区、引用优先级、审核状态等。
6. 请说明 Package 3 是否包含真实法规、监管文件、内部模板的导入，还是只包含结构和 starter 设置。

7. 请说明本地 RAG starter 使用什么向量数据库、embedding 模型、chunking 策略和 reranking 方案。
8. 请说明法律文本 chunking 是否会按法条、章节、条款层级处理，还是采用通用文本切分。
9. 请说明 RAG 检索结果是否支持来源引用、版本管理和律师复核标记。
10. 请说明 Pacgate 后续能否自行扩充、导出、迁移知识库和向量索引。
11. 请说明贵方所谓 context graph 和 NetDocuments Legal Context Graph / GraphRAG 的关系：Phase 1 能做到什么程度，哪些留到 Phase 2？
12. 是否可以在 Phase 1 建立轻量数据结构：client、matter、document、authority、playbook、agent run、review decision、delivery package？
13. 未来如果系统 2 SaaS 化，这套 context graph 是否可以直接延续，而不是重做？
14. 外部 MCP 检索结果是否可以和内部 RAG 检索结果一起进入同一个 agent workflow，并分别标注来源？
15. 系统是否支持区分“外部权威法源”和“Pacgate 内部经验”，避免 AI 把内部建议误当成法律依据？
16. 律师是否可以对外部检索结果和内部知识结果进行确认、驳回、标记优先级，并反馈到后续 workflow？

十、律师使用入口、客户入口与自动化测试

1. Phase 1 中律师日常使用入口是什么？Open WebUI、OpenSpace、Lavern 前端、Claude plugin、飞书 Bot，还是本地文件夹监听？
2. 是否包含飞书 Bot 或飞书工作流接入？如果不包含，请说明预计需要多少顾问小时可完成最小可用版本。
3. 是否包含本地文件夹自动监听、上传材料自动触发分析、生成报告草稿等自动化能力？
4. 请列出 Phase 1 完成后，Pacgate 律师可以实际操作的 3 至 5 个具体场景。
5. 请说明每个场景的输入材料、操作步骤、系统输出和律师复核点。
6. 如未来接入微信、飞书、邮件或网页表单，哪些入口最适合作为系统 2 种子客户内测入口？请说明理由。

十一、安全、权限与数据边界

1. 请说明所有客户文件、解析文本、向量库、日志和输出是否默认保存在 Pacgate 控制的本地设备内。
2. 请说明哪些情况下数据会发送至外部模型或第三方服务，是否可以完全关闭外部调用。
3. 请说明 IronClaw 在 Phase 1 中具体负责哪些安全边界、审批机制或权限控制。
4. 请说明日志是否会记录客户文件正文、prompt、模型输出等敏感信息，是否支持脱敏或关闭。
5. 请说明系统是否支持不同客户或 matter 之间的数据隔离。
6. 请说明种子客户内测时是否可以设置免责声明、客户授权、数据使用范围和输出非正式法律意见提示。
7. 请说明外部法律数据库 MCP、外部 LLM API、Cubecloud 远程运维分别涉及哪些数据出域风险。

十二、系统 2 SaaS 化的工作内容与报价区间

1. 请说明贵方所称 Phase 2 SaaS 化具体包括哪些模块：客户门户、律师后台、matter 系统、权限隔离、RAG、计费、日志审计、运维监控等。
2. 请分别提供系统 2 SaaS 化的三档方案：种子客户内测版、MVP 商业版、正式平台版。
3. 请分别列明三档方案的功能范围、预计周期、团队配置、硬件要求、是否复用 Phase 1 成果、预算区间和主要风险。
4. 请说明系统 2 SaaS 化时，是更适合部署在 Pacgate 自有本地服务器、私有云、公有云，还是混合架构。
5. 请说明 SaaS 化后客户数据是否仍可默认留在 Pacgate 控制环境中，外部模型调用如何控制。
6. 请说明从 Phase 1 Lavern 原型走向 Phase 2 SaaS，哪些部分可以复用，哪些部分需要重构。
7. 请说明是否需要新增客户账号系统、企业组织管理、客户权限、律师权限、管理员后台、通知系统和客户支持系统。
8. 请说明是否需要新增商业化模块，如套餐、订阅、用量统计、账单、发票、客户管理和服务记录。
9. 请说明系统 2 如果未来支持多个客户同时使用，数据库、多租户隔离、文件存储和向量库隔离如何设计。
10. 请说明 Phase 2 的粗略预算区间：种子客户内测版、MVP 商业版、正式平台版分别大约需要多少预算。

十三、验收、付款与后续支持

1. 请为 60% kickoff、30% Milestone 1、10% final handover 分别提供明确验收标准。
2. 请说明如果 Milestone 1 未达到“本地系统可运行”标准，整改周期和责任如何安排。
3. 请说明 final handover 包含哪些文档：部署说明、账号清单、操作手册、故障排查、数据导出指南等。
4. 请说明 40 小时远程顾问的使用方式：是否按实际工时扣减，是否提供工时记录，未使用小时是否可顺延。
5. 请说明额外 workflow、connector、飞书接入、模型优化、硬件扩容分别如何报价。
6. 请说明 Phase 1 结束后，Pacgate 若决定不进入 Phase 2，是否仍拥有完整使用权、数据所有权和继续自研的能力。
7. 请分别为系统 1 和系统 2 提供独立验收标准，不要混在同一个“法律 Agent 适配”交付项里。
8. 请说明是否可以按每 10 小时顾问服务形成一次可验证成果或阶段总结。

十四、知识产权与开源合规

1. 请说明 Claude for Legal、Lavern 及其他开源项目的许可证义务由谁负责识别和遵守。
2. 请说明 Pacgate 在开源项目基础上的修改、prompt、workflow、playbook、知识库结构和配置文件，知识产权是否归 Pacgate 所有。
3. 请说明贵方交付的脚本、配置、文档、prompt、workflow 是否允许 Pacgate 复制、修改、迁移和用于后续商业化。
4. 请说明是否存在任何 Cubecloud 专有组件导致 Pacgate 后续无法独立迁移或运行。
5. 请说明如系统 2 未来 SaaS 化或商业化，Claude for Legal、Lavern、Mike、Suzie Law 等开源项目的许可证是否会对商业化产生限制。
6. 请说明开源项目 fork、二次开发、内部部署、客户使用和外部商业化各自对应的合规要求。

十五、建议回复格式

问题编号	贵方回复	交付归类	预计时间 / 成本	备注
示例：二-1	请逐项书面说明	固定交付 / 顾问小时 / 另行报价 / 暂不支持 / 待确认	如适用，请填写	如涉及风险、前提或第三方依赖，请说明